

Trabajo Práctico Final

Regresión Avanzada

Maestría en Explotación de Datos y Gestión del Conocimiento

Universidad Austral

Dra. Luciana Chiapella - Mg. Diego Marfetán Molina

Año 2026

Descripción del conjunto de datos

La Encuesta Permanente de Hogares (EPH) es un relevamiento realizado de manera continua por el Instituto Nacional de Estadística y Censos (INDEC) de la República Argentina. Su principal objetivo es producir información sistemática sobre las características sociodemográficas y las condiciones de empleo e ingreso de la población urbana del país. La encuesta se realiza en los principales aglomerados urbanos del país y releva información a nivel de hogares y de personas.

Los microdatos de la EPH constituyen una de las principales fuentes de información para el análisis del mercado laboral y las condiciones socioeconómicas en Argentina.

En este trabajo práctico se utilizará un subconjunto de microdatos de la EPH correspondiente a personas cuya condición de actividad laboral al momento de la encuesta (3er trimestre de 2025) era *Ocupado*, que manifestaron tener un ingreso económico por su ocupación principal y que trabajaban como empleados u obreros. La información se encuentra almacenada en la planilla de Excel `eph.xlsx`.

Diccionario de variables

Variable	Descripción
sexo	Sexo del encuestado (Hombre / Mujer)
edad	Edad del encuestado, en años cumplidos
est_civil	Estado civil (soltero/a, unido/a, casado/a, separado/a o divorciado/a, viudo/a)
region	Región donde se realiza la encuesta (Gran Buenos Aires, Cuyo, Noreste, Noroeste, Pampeana, Patagonia)
educ_cat	Mayor nivel educativo completado por el encuestado (Ninguno, Primario, Secundario, Superior)
ant_laboral	Antigüedad laboral en la ocupación principal actual
formal	Indica si la ocupación principal del encuestado se encuentra formalmente registrada
horas_trabajo	Cantidad de horas trabajadas la semana anterior a la encuesta
ingreso_ocup	Ingreso habitual mensual recibido por la ocupación principal (en miles de pesos)
ingreso_hogar	Ingreso habitual mensual total de los integrantes del hogar (en miles de pesos)
ingreso_per_capita	Ingreso habitual mensual del hogar dividido la cantidad de integrantes del mismo (en miles de pesos)

Consigna I: Regresión Lineal

1. Dividir aleatoriamente al conjunto de datos en bloques de entrenamiento (70%) y prueba (30%), definiendo una semilla para hacer que el resultado sea reproducible. Salvo que se exprese lo contrario, todas las consignas presentadas a continuación deben responderse empleando el conjunto de datos de entrenamiento.
2. Ajustar tres modelos diferentes de Regresión Lineal Múltiple con el método de los Mínimos Cuadrados Ordinarios (MCO), definiendo como variable respuesta al ingreso mensual recibido por la ocupación principal. Se debe justificar por qué se eligieron a esos tres modelos en particular (ejemplo: procesos automáticos, técnica del mejor subconjunto, criterios propios, etc.).
3. Comparar los 3 modelos a través de las siguientes métricas de performance: CME, PRESS, AIC y BIC. En base a los resultados observados, elegir un modelo “ganador”.

4. Realizar un análisis de residuos sobre el modelo seleccionado en el punto anterior. Este análisis debe incluir el chequeo de cumplimiento de supuestos, presencia de colinealidad y casos atípicos y/o influyentes.
5. Considerando el modelo elegido, interpretar en palabras del problema los efectos estimados de los predictores sobre la respuesta, incluida su significación estadística (resultados del test t).

Consigna II: Regularización y Predicción

1. Ajustar el modelo elegido en el punto anterior mediante la técnica Ridge, eligiendo el parámetro de penalidad mediante validación cruzada k -fold. Informar el valor óptimo de λ y comparar el resultado de este ajuste con el obtenido mediante MCO.
2. Ajustar el modelo elegido en el punto anterior mediante la técnica Lasso, eligiendo el parámetro de penalidad mediante validación cruzada k -fold. Informar el valor óptimo de λ y comparar el resultado de este ajuste con el obtenido mediante MCO.
3. Evaluar la capacidad predictiva de los modelos MCO, Ridge y Lasso por intermedio de alguna medida del error de predicción, y determinar cuál de los tres modelos es el más adecuado para este ejemplo. Utilizar en este punto el bloque de **datos de prueba**.

Consigna III: Regresión Logística

1. Sobre el conjunto de datos original, definir la variable respuesta:

$$Y_i = \begin{cases} 0 & \text{si } ingreso_ocup_i < 1000 \\ 1 & \text{si } ingreso_ocup_i \geq 1000 \end{cases}$$

2. Dividir aleatoriamente al conjunto de datos inicial en bloques de entrenamiento (70%) y prueba (30%), definiendo una semilla para hacer que el resultado sea reproducible. Utilizar la función `createDataPartition()` del paquete `caret` para asegurarse que la proporción de éxitos en cada partición sea balanceada.
3. Ajustar un modelo de regresión logística para estudiar la variable binaria definida en el punto 1. Este modelo debe incluir las mismas variables explicativas que el modelo elegido en la Consigna I. En base al resultado obtenido, interpretar las razones de odds asociadas a predictores estadísticamente significativos al 5%.
4. Elegir el punto de corte óptimo para clasificación mediante el método de la curva ROC.
5. Utilizando el punto de corte hallado, clasificar los individuos del conjunto de datos de prueba y construir la matriz de confusión correspondiente. Informar e interpretar los valores observados de precisión, sensibilidad, especificidad, VPP y VPN.

Indicaciones

- Se deben entregar 2 archivos:
 1. Archivo en formato .pdf con **15 hojas de extensión como máximo** donde figuren las respuestas para cada una de las consignas. Si bien no es obligatorio, se recomienda el uso de R Markdown o Quarto para generar el documento.
 2. Archivo en formato .Rmd o .qmd que permita generar el reporte enviado, o bien un script de R con las sentencias utilizadas para el ajuste y análisis de los modelos.
- **Fecha de Entrega:** 18/05/2026 a través del aula virtual.
- **Equipos:** se permite trabajar individualmente o en grupos de 2 personas como máximo. Se deben informar los grupos por medio de un correo electrónico dirigido a ambos docentes (DMarfetan-ext@austral.edu.ar - LChiapella-ext@austral.edu.ar).

!!!Éxitos!!!