

Trabajo Práctico Final

Regresión Avanzada — Maestría en Explotación de Datos y Gestión del Conocimiento

Universidad Austral

2026-05-01

1 Consigna I: Regresión Lineal

1.1 Partición train/test (I.1)

Se dividió aleatoriamente el conjunto de datos en **bloque de entrenamiento (70%)** y **bloque de prueba (30%)**, fijando `set.seed(123)` para garantizar reproducibilidad.

La partición resultó en **7.146 observaciones de entrenamiento** y **3.062 de prueba**.

1.2 Ajuste de tres modelos MCO (I.2)

Se ajustaron tres modelos de Regresión Lineal Múltiple tomando `ingreso_ocup` como variable respuesta:

Modelo 1 — Criterio sustantivo/parsimonia: incluye predictores directamente vinculados al ingreso laboral individual: características personales (sexo, edad, educación) y laborales (formalidad, horas, antigüedad).

Modelo 2 — Modelo amplio: extiende el anterior incorporando variables demográficas (estado civil), territoriales (región) y de contexto del hogar (`ingreso_hogar`).

Modelo 3 — Selección automática (stepAIC): aplica selección bidireccional sobre el espacio del Modelo 2. En este caso el procedimiento no eliminó variables, resultando idéntico al Modelo 2.

1.3 Comparación y selección del modelo ganador (I.3)

Se compararon los modelos mediante CME, PRESS, AIC y BIC. Menores valores indican mejor desempeño en todos los casos.

Tabla 1: Comparación de métricas de performance — entrenamiento

Modelo	CME	PRESS	AIC	BIC
Modelo 1	339.758	2.435.976.445	111.321	111.424
Modelo 2	260.857	1.980.852.790	109.452	109.624
Modelo 3	260.857	1.980.852.790	109.452	109.624

Modelo ganador: Modelo 2. Superó al Modelo 1 en todas las métricas. El Modelo 3 (stepAIC) coincidió exactamente con el Modelo 2, confirmando que el modelo amplio ya era óptimo según AIC/BIC. La fórmula del modelo ganador es:

ingreso_ocup ~ sexo+edad+est_civil+region+educ_cat+ant_laboral+formal+horas_trabajo+ingreso_hoga

1.4 Análisis de residuos y supuestos (I.4)

Los gráficos de diagnóstico se construyeron sobre el modelo ganador. Se muestran los más relevantes:




Figura 1: Izq: Residuos vs. ajustados. Der: QQ-plot de residuos.




Figura 2: Izq: Distancia de Cook (umbral $4/n$ en rojo). Der: Leverage por observación (umbral $2p/n$ en rojo).

Normalidad: Los datos no siguen una distribución normal: el test de Shapiro-Wilk dio $W = 0.732$, $p\text{-value} < 2.2e-16$ con un valor p extremadamente bajo, por lo que se rechaza la normalidad. El gráfico también muestra desviaciones claras, sobre todo en los valores más altos. Como la muestra es muy grande (más de 7.000 casos), los resultados generales del análisis

siguen siendo confiables. Sin embargo, las predicciones individuales pueden ser menos precisas y conviene tomarlas con cautela.

Homocedasticidad: El test de **Breusch-Pagan** arrojó **BP = 2938.1**, **p-value < 2.2e-16**, confirmando la heterocedasticidad detectada visualmente. Los errores estándar y los p-values reportados por MCO pueden estar sesgados en este contexto.

Multicolinealidad: Los valores $\text{GVIF}^{1/(2 \cdot \text{Df})}$ resultaron bajos para todas las variables (máximo 1.27 para **edad**). **No se detectó multicolinealidad severa.**

Tabla 2: VIF ajustados del modelo ganador (todos < 5: sin problema de colinealidad)

Variable	GVIF ajustado
sexo	1.142
edad	1.272
est_civil	1.050
region	1.008
educ_cat	1.050
ant_laboral	1.062
formal	1.237
horas_trabajo	1.087
ingreso_hogar	1.065

Observaciones atípicas e influyentes:

Tabla 3: Resumen de observaciones problemáticas

Criterio	Cantidad de casos
$ \text{residuo estandarizado} > 3$	110
$ \text{residuo estudentizado} > 3$	110
Leverage alto ($> 2p/n$)	395
Distancia de Cook $> 4/n$	219

La presencia de estos casos es consistente con la heterocedasticidad observada y es esperable en datos de ingresos, donde hay una cola derecha de salarios muy altos que generan residuos grandes.

1.5 Interpretación de coeficientes y tests t (I.5)




Figura 3: Coeficientes estimados del modelo ganador. Verde: significativos al 5%.

La interpretación de cada coeficiente se realiza **manteniendo constantes todas las demás variables del modelo** (efecto parcial). Los predictores estadísticamente significativos al 5% son:

sexoMujer ($\beta = -158.16$, $p < 0.001$): Las mujeres presentan, en promedio, un ingreso mensual por ocupación principal **\$158.160 menor** que los varones en condiciones equivalentes. La brecha salarial de género es estadísticamente muy significativa.

edad ($\beta = 3.84$, $p < 0.001$): Por cada año adicional de edad, el ingreso mensual esperado aumenta en promedio **\$3.840**, reflejando la acumulación de experiencia laboral.

est_civilsoltero ($\beta = -66.83$, $p < 0.001$): Ser soltero se asocia con un ingreso esperado **\$66.830 menor** respecto de la categoría de referencia del estado civil.

region: Respecto de la región de referencia (Cuyo):

- Gran Buenos Aires: +\$110.990 ($p < 0.001$)
- Noroeste: -\$117.110 ($p < 0.001$) ← menor ingreso relativo
- Noreste: -\$60.730 ($p = 0.039$)
- Pampeana: +\$55.980 ($p = 0.013$)
- **Patagonia: +\$283.600 ($p < 0.001$)** ← mayor ingreso relativo

educ_cat: Respecto del nivel educativo de referencia:

- Secundario completo: +\$113.570 ($p = 0.010$)
- **Superior: +\$385.490 ($p < 0.001$)** ← efecto positivo muy fuerte

ant_laboral: Respecto de la categoría de referencia:

- Más de 5 años: +\$76.750 ($p = 0.025$) — mayor antigüedad, mayor ingreso
- Menos de 1 mes: -\$245.180 ($p < 0.001$) — menor ingreso en inicios laborales

formalSi ($\beta = +235.87$, $p < 0.001$): Tener una ocupación formal está asociado con un ingreso mensual **\$235.870 mayor** en promedio. Es uno de los efectos más fuertes del modelo.

horas_trabajo ($\beta = 9.45$, $p < 0.001$): Por cada hora adicional trabajada en la semana previa, el ingreso mensual esperado aumenta en **\$9.450**.

ingreso_hogar ($\beta = 0.1299$, $p < 0.001$): A mayor ingreso total del hogar, mayor ingreso individual. El efecto marginal es positivo aunque pequeño.

En conjunto, **sexo, formalidad, educación, región y antigüedad** son los predictores con mayor impacto sobre el ingreso laboral.

2 Consigna II: Regularización y Predicción

2.1 Ridge con selección de λ por validación cruzada (II.1)

Se ajustó el modelo ganador mediante **Ridge** ($\alpha = 0$) seleccionando λ por validación cruzada k-fold (10 folds). El λ **óptimo** fue $\lambda = 96.35$ ($\lambda_{1se} = 679.74$).

Ridge conserva todas las variables del modelo, pero **contrae los coeficientes hacia cero**, reduciendo la varianza de las estimaciones a costa de introducir sesgo. Los coeficientes mantienen el mismo signo que en MCO con magnitudes menores.

Comparación Ridge vs. MCO: Ridge introduce sesgo a cambio de menor varianza, lo que puede mejorar la capacidad predictiva fuera de muestra, especialmente cuando hay multicolinealidad moderada o alta dimensionalidad. En este caso, los VIF eran bajos, por lo que la mejora predictiva de Ridge puede ser modesta.

2.2 Lasso con selección de λ por validación cruzada (II.2)

Se ajustó el modelo ganador mediante **Lasso** ($\alpha = 1$) con el mismo procedimiento. El λ **óptimo** fue $\lambda = 0.746$ ($\lambda_{1se} = 59.12$).

Lasso realizó **selección automática de variables**, anulando coeficientes como `educ_catPrimario` y `ant_laboral1` a 5 años. El modelo resultante retuvo **22 coeficientes no nulos** (incluyendo intercepto), produciéndose un modelo más parsimonioso que MCO.

Comparación Lasso vs. MCO: Lasso combina estimación y selección de variables. Las variables eliminadas tienen efecto marginal pequeño en el contexto del modelo. Los coeficientes retenidos tienen menor magnitud que en MCO por el efecto shrinkage.

2.3 Performance predictiva en test (II.3)

Tabla 4: Performance predictiva en el conjunto de prueba (miles de pesos)

Modelo	RMSE	MAE	MSE
Ridge	491	292	241.261
MCO	494	292	243.717
Lasso	494	292	243.782




Figura 4: Valores observados vs. predichos en el conjunto de prueba — Modelo Ridge.

El modelo con mejor capacidad predictiva fue Ridge, con el menor RMSE (491) y MSE (241.261). Las diferencias entre los tres modelos son pequeñas — todos predicen el ingreso con un error típico de aproximadamente **\$491.000** en datos no vistos.

Conclusión: Para fines **predictivos**, Ridge es preferible. Para fines **inferenciales e interpretativos**, MCO sigue siendo el modelo más adecuado por la claridad de sus coeficientes, tests t e intervalos de confianza. Lasso es útil cuando se busca simultáneamente selección de variables y predicción, aunque en este caso la mejora fue marginal respecto de Ridge.

3 Consigna III: Regresión Logística

3.1 Definición de la variable binaria (III.1)

Se definió la variable respuesta binaria:

$$Y_i = \begin{cases} 0 & \text{si ingreso_ocup}_i < 1.000 \\ 1 & \text{si ingreso_ocup}_i \geq 1.000 \end{cases}$$

La distribución resultó:

- **Clase 0 (ingreso < 1.000):** 6.668 casos (65.32%)
- **Clase 1 (ingreso ≥ 1.000):** 3.540 casos (34.68%)

Las clases están **desbalanceadas** — hay aproximadamente el doble de personas con ingresos bajos. El uso de `createDataPartition()` garantiza preservar esta proporción en ambas particiones.

3.2 Partición balanceada (III.2)

La proporción de éxitos quedó prácticamente idéntica en ambas particiones (**34.68% en train, 34.68% en test**), confirmando la correcta estratificación.

3.3 Modelo logístico e interpretación de odds ratios (III.3)

Se ajustó un modelo de regresión logística binaria con las mismas variables explicativas que el modelo ganador de la Consigna I.

El modelo convergió correctamente. Se emitió un warning de probabilidades extremas cercanas a 0 o 1 en algunas observaciones, lo cual es esperable con ingresos muy altos o muy bajos.




Figura 5: Odds ratios significativas al 5% con IC al 95%. Línea punteada = OR = 1 (sin efecto).

Interpretación de las odds ratios significativas al 5% (efecto sobre las odds de tener ingreso 1.000, manteniendo constantes las demás variables):

sexoMujer (OR = 0.46): Las mujeres tienen odds de percibir ingresos altos **54% menores** que los varones en iguales condiciones. La brecha de género es muy marcada.

edad (OR = 1.02): Cada año adicional de edad incrementa las odds de ingreso alto en aproximadamente un **2%**.

est_civilsoltero (OR = 0.72): Los solteros tienen odds un **28% menores** que la categoría de referencia.

region:

- GBA (OR = 1.74): odds un **74% mayores** que Cuyo
- Noreste (OR = 0.63): odds un **37% menores**
- Noroeste (OR = 0.43): odds un **57% menores**

- Pampeana ($OR = 1.40$): odds un 40% **mayores**
- **Patagonia ($OR = 4.79$): odds casi 5 veces mayores** — diferencia regional más pronunciada

educ_cat:

- Secundario ($OR = 1.95$): odds casi el **doble** respecto de la referencia
- **Superior ($OR = 4.58$): odds más de 4 veces mayores** — educación superior es el predictor individual más fuerte

ant_laboral Mas de 5 años ($OR = 2.21$): Más de 5 años de antigüedad **duplica** las odds de ingreso alto.

formal Si: La formalidad laboral incrementa sustancialmente las odds de superar el umbral de ingreso (coeficiente positivo y muy significativo).

horas_trabajo y **ingreso_hogar**: Efectos positivos y significativos, consistentes con la Consigna I.

3.4 Curva ROC y punto de corte óptimo (III.4)




Figura 6: Curva ROC sobre el conjunto de entrenamiento. $AUC = 0.8931$. Punto de corte óptimo (Youden) = 0.3382.

El modelo logístico alcanzó un **AUC = 0.893** en el conjunto de entrenamiento, indicando **muy buena capacidad discriminante** para diferenciar personas con ingresos altos y bajos.

El punto de corte óptimo según el **índice de Youden** fue **$p^* = 0.338$** , sustancialmente menor al convencional de 0.5. Esto refleja el desbalanceo de clases (65% clase 0): usando un umbral más bajo, el modelo captura más verdaderos positivos a costa de algo más de falsos positivos — equilibrio adecuado para este problema.

3.5 Clasificación en test y matriz de confusión (III.5)




Figura 7: Heatmap de la matriz de confusión — conjunto de prueba.

La matriz de confusión resultante sobre el conjunto de prueba fue:

Tabla 5: Matriz de confusión — conjunto de prueba

	Real: 0	Real: 1
Predicho: 0	1.529 (VN)	180 (FN)
Predicho: 1	471 (FP)	882 (VP)

Tabla 6: Métricas de clasificación en el conjunto de prueba

Métrica	Valor	Interpretación
Accuracy	0.787	Proporción de clasificaciones correctas
Sensibilidad	0.831	Prop. de ingresos altos correctamente identificados
Especificidad	0.764	Prop. de ingresos bajos correctamente identificados
VPP	0.652	Prob. de ingreso alto dado que el modelo lo predijo
VPN	0.895	Prob. de ingreso bajo dado que el modelo lo predijo

Interpretación de las métricas:

- **Accuracy = 0.787:** El modelo clasifica correctamente **casi 8 de cada 10** individuos del conjunto de prueba.
- **Sensibilidad = 0.831:** Identifica correctamente el **83.1% de los individuos con ingreso 1.000** (verdaderos positivos). Alta capacidad para detectar el grupo de ingresos altos.
- **Especificidad = 0.764:** Clasifica correctamente el **76.4% de los individuos con ingreso < 1.000** (verdaderos negativos). Algo menor que la sensibilidad, lo que refleja el trade-off del punto de corte elegido.
- **VPP = 0.652:** Entre quienes el modelo predice como ingreso alto, el **65.2% efectivamente pertenece a esa categoría**. Hay un 34.8% de falsos positivos entre los clasificados como “alto”.

- **VPN = 0.895:** Entre quienes el modelo predice como ingreso bajo, el **89.5%** efectivamente tiene ingreso < 1.000 . Alta confiabilidad en la predicción negativa.

Conclusión general: El modelo logístico presenta un desempeño **bueno y balanceado**. El AUC de 0.893 indica excelente discriminación. La elección del umbral de Youden (0.338) produjo un balance razonable entre sensibilidad y especificidad, con especial fortaleza para detectar correctamente a los individuos del grupo de ingresos altos.